

بسمه تعالی



دانشگاه شهید بهشتی

دانشکده علوم ریاضی

گزارش مقاله

استاد : دکتر سعیدرضا خردپیشه

حنانه حبیبی 96222029

فهرست

2	تمرین سوم.....
3	معرفی.....
3	SDNN پیشنهادی.....
4	DoG و کدگذاری زمانی.....
5	لایه های convolutional.....
5	لایه های Pooling محلی.....
6	یادگیری STDP_based.....
7	تمرین 4 – R-STDP.....
8	ساختار شبکه.....
9	Overfitting.....
9	Classification.....
9	توضیحات کلی.....
10	جمع بندی.....

تمرین سوم

در این قسمت یک گزارش از مقاله STDP-based spiking deep convolutional neural networks for object recognition شرح می‌دهم.

تشخیص بصری اشیا یک کار پیچیده است که انسان در آن متخصص است. این وظیفه هم به استخراج ویژگی نیاز دارد که توسط قشر بینایی مغز انجام می‌شود و همینطور تصمیم‌گیری در مورد دسته‌بندی جسم، که مناطق بالاتر مغز در آن دخیل هستند. شبکه‌های عصبی اسپایکی (SNN) به طور گسترده‌ای در مدل‌های تشخیص شی محاسباتی استفاده شده است.

مطالعات قبلی نشان داده است که از STDP میتوان برای استخراج ویژگی‌های بصری با پیچیدگی کم یا متوسط به روشی بدون نظارت در شبکه‌های اسپایکی استفاده کرد. در این مطالعات از shallow SNN استفاده کرده و از یک لایه یادگیری استفاده میشد. در این تحقیقات از یک SNN عمیق استفاده شده است و در آن یک مدل اسپایکی LIP با ساختار convolutional وجود دارد. در این شبکه به جای یک لایه یادگیری را در کل شبکه داریم. در این تحقیقات از یک temporal coding استفاده شده که نورون‌های فعالتر زودتر fire میکنند. به خاطر استفاده از STDP نورون‌ها به تدریج ویژگی‌های الگوهای نمونه را یادگرفتند و نیازی به تعداد نمونه بسیار زیاد و برجسب گذاری هم نبوده است. درجه پیچیدگی یادگیری هم به صورت سلسله مراتبی فرایند شناسایی از خط تا نمونه اولیه شی در لایه آخر افزایش می‌یابد.

فرق این شبکه با شبکه‌های عادی در این است که نورونهای این شبکه اسپایکی هستند، شبیه چیزی که در مغز وجود دارد. بیشتر از یک لایه قابل یادگیری دارند که میتواند تصاویر شی را در مقیاس بزرگ پردازش کنند. در اینجا مثل شبکه‌های عادی یادگیری supervised backpropagation نداریم. به دلیل استفاده از یک برنامه نویسی زمانی کارآمد، که اطلاعات بصری را در زمان اسپایک‌های اولیه کد می‌کند، می‌تواند تصاویر ورودی را با تعداد کمی اسپایک و در چند مرحله زمان پردازش کند. یادگیری STDP است و کدینگ خیلی بهینه است. همگرایی خوب و سریعی دارد و برای فشرده‌سازی فیچرها برخلاف شبکه‌های عادی الزاما میلیون‌ها تصویر احتیاج نیست. چون یادگیری در اینجا unsupervised است میتواند از overfitting جلوگیری شود.

معرفی

سیستم بینایی اولیه وظیفه تشخیص شی در یک پردازش سلسله مراتبی در امتداد مسیر شکمی قشر بینایی را دارد. این روند سلسله مراتبی به این شکل است که در ناحیه V1 که اولین ناحیه است به تشخیص خط ها و لبه ها میپردازد، در ناحیه V2 و V4 به تشخیص شکلها و اشیا و در ناحیه انتهایی که IT است به تشخیص چهره و اشکال پیچیده میپردازد. اولین موج اسپایک در IT برای شناسایی و تشخیص جسم خام کافی است.

دامنه و مدت زمان اسپایک ها تقریباً یکسان است، بنابراین با زمان انتشار میتوان آنها را مشخص کرد. در سیستم بینایی اولیه تعداد اسپایک ها بسیار کم است. برخی اطلاعات را میتوان در زمان اسپایک ها کدگذاری کرد که منجر به یک محاسبه عصبی سریع و با انرژی پایین میشود.

با کمک STDP میتوان یک یادگیری بدون نظارت انجام داد. طبق این یادگیری سیناپسهای که اسپایک نوروں presynaptic شان قبل از نوروں postsynaptic برسد تقویت میشوند.


ایده اصلی این است که هر واحد DCNN را با یک نوروں اسپایکی که firing rate آن با خروجی آن واحد مرتبط است جایگزین کنیم. هدف این شبکه کاهش انرژی مصرفی در DCNN است. یک اشکال این شبکه زمان پردازش بالا و نیاز به تعداد اسپایک زیاد برای هر تصویر است.

در این مقاله یک SDNN بر مبنای STDP با یک کدینگ spiketime پیشنهاد شده است. در این شبکه از چندین لایه convolutional و pooling استفاده شده است. در آخر یک classifier گروه ورودی را با توجه به فعالیت نوروں ها در آخرین لایه پولینگ با global receptive field مشخص میکند. لایه های convolution عملکردی شبیه simple cell ها دارند و سعی میکنند فیچر استخراج کنند و لایه های pooling عملکردی شبیه به complex cell ها دارند و بین یک سری از نوروںهایی که میبینند عمل ماکسیمم گیری انجام میدهند. در همه شبکه از نوروںهای IF استفاده شده است.

SDNN پیشنهادی با مجموعه داده چهره/موتورسیکلت و ETH-80 در مقیاس بزرگ و کوچک و از زاویه دیدهای متفاوت و داده های MNIST نتیجه خیلی خوبی داشته است. این شبکه علاوه بر عملکرد بالا، دارای انرژی مصرفی پایین و استفاده از تعداد اسپایک کم در هر تصویر است که آن را برای پیاده سازی سخت افزار نورومورفیک مناسب می کند.

SDNN پیشنهادی

تصویر زیر نمونه ای از این شبکه با سه لایه کانولوشن و سه لایه پولینگ است.



لایه اول فیلتر DoG است که contrast را در ورودی تشخیص می دهد و میزان یا قدرت آنرا به صورت اسپایک کد میکند. نورن ها در لایه های کانولوشن با ادغام اسپایک های لایه قبلی که اطلاعات ساده تری را تشخیص میدهند، ویژگی های پیچیده تری را تشخیص میدهند و بعد یک اسپایک میزنند. در طی یادگیری نورون هایی که زودتر فایر میکنند STDP را انجام میدهند و با مکانیزم winner-takeall جلوی فایر کردن بقیه را میگیرند. بدین ترتیب شبکه ویژگی های بارزتر و پرتکرارتری را می آموزد. در لایه های Pooling هم به ماکسیمم سازی و فشرده سازی داده پرداخته میشود. همانطور که در تصویر پیداست لایه های Convolutional و Pooling به صورت متوالی مرتب شده اند. Receptive fields به تدریج با جلوتر رفتن در شبکه افزایش میابد و نورون ها در لایه های بالاتر به شناخت و تشخیص اشیا پیچیده یا قسمت هایی از آنها میپردازند.

DoG و کدگذاری زمانی

نفس مهم مرحله اول SNN کدگذاری ورودی سیگنال در یک اسپایک به طور گسسته در یک دامنه زمانی است. این کدگذاری زمانی محتوا و میزان اطلاعاتی که هر اسپایک دارد را تعیین میکند. از این رو استفاده از یک الگوری کدگذاری کارآمد میتواند سرعت و دقت پاسخ را تا حد زیادی افزایش دهد. یکی از شیوه ها rank-order است که پردازش سریع و کارامدی دارد.

سلولهای لایه اول که فیلتر DoG هستند کنتراستهای مثبت و منفی را در ورودی نشان میدهند و یک اسپایک میزنند. این لایه به خوبی خصوصیت center-surround در سلولهای ganglion شبکیه را تقریب میزنند.

هرچه کنتراست بیشتر باشد سلول زودتر fire میکند. کدگذاری Rank-order نشان داده است که برای به دست آوردن V1 و همینطور ویژگی های بصری پیچیده تر در قشرهای بالاتر مناسب است.

لایه های convolutional

در لایه های کانولوشن هر یک از نورون ها براساس وزن سیناپس ورودیشان انتخاب میشوند که یک ویژگی بصری را استخراج کنند. نورنهای موجود در یک مپ خاص یک ویژگی یکسانی را تشخیص میدهند. پنجره های ورودی دو نورون مجاور بسیار همپوشانی دارند. از این رو، شبکه می تواند ظاهر ویژگی های بصری را در هر مکان تشخیص دهد.

نورنهای در هر لایه کانولوشن nonleaky IF هستند که اسپایک های ورودی از نورون قبلی را گرفته و بعد از رسیدن پتانسیل داخلی آنها به آستانه خود اسپایک میزنند.

یک مکانسیم مهاری در تمام نورنهای این لایه وجود دارد. وقتی نورونی در یک مکان خاص فایر میکند نورن های دیگر آن مکان وابسته به مپ های دیگر را مهار میکند تا فایر نکنند تا ورودی بعدی. هر کدام از نورون ها تنها مجاز به یک دفعه فایر کردن هستند.

در لایه convolutional اول orientationها به دست می آیند در لایه دوم آن object partها به دست می آیند و در لایه convolutional آخر هم full object را به دست می آوریم.

لایه های Pooling محلی

نورنهای این لایه با انجام عملیات max pooling غیرخطی روی نورنهای در یک همسایگی کمک میکنند که invariance افزایش پیدا کند. نورنهای پولینگ همه نورنهای IF هستند که وزن ورودی سیناپس ها و آستانه آنها همگی روی یک تنظیم شده است. از این رو اولین اسپایک ورودی آنها را فعال کرده و منجر به اسپایک زدن میشود. هر نورون در این لایه هم حداکثر یک دفعه فایر میکند. در این لایه هیچ یادگیری اتفاق نمی افتد.

این لایه محدوده ای که میبیند از صفح متناظر خودش در لایه convolution قبلی ورودی میگیرد. پس روی نورنهایی که فیچر مشابه دارند pooling انجام میدهد.

همپوشانی اطلاعات در دو پنجره ورودی از دو نورون مجاور در لایه Pooling که به یک مپ تعلق دارند خیلی کم شده است.

یادگیری STDP_based

یادگیری فقط در لایه کانولوشن و به صورت لایه لایه انجام میشود. به این ترتیب که نورون های این لایه یاد میگیرند با ترکیب کردن اطلاعات ساده تری که در لایه های قبل استخراج شده است ویژگی های بصری پیچیده تری را تشخیص دهند. این ترکیب ها به نسبت وزن های نورونها انجام میشود. وزنها از قاعده STDP به دست می آیند. یعنی اگر نورون convolution مان فایر کند تمام نورونهای ورودی اش قبل از آن فایر کرده باشند وزنش افزایش میابد و مابقی وزنشان کاهش میابد.

نورنهای یک صفحه باید وزنشان شبیه هم باشد. در یک صفحه اولین نورونی که فایر کند STDP را اعمال میکند و تغییرات وزنش را روی تمام نورونهای دیگر آن صفحه به اشتراک میگذارد. چون اطلاعات در زمان کد میشود.

در اینجا انتظار میرود DoG شبیه شبکیه عمل کند، لایه convolutional اول شبیه V1 و لایه convolutional دوم شبیه V2 و V4 عمل کند و لایه convolutional سوم هم شبیه لایه IT باشد.

در آخر این توالی لایه ها global pooling اتفاق می افتاد که در نهایت یک بردار به دست می آید و بعد اینها در یک external classifier کار طبقه بندیشان انجام میشود.

تمرین 4 – R-STDP

SNN از نظر دقت و سرعت پتانسیل بالایی برای پردازش موثر اطلاعات دارند. از طرف دیگر، آموزش این نوع شبکه ها بسیار دشوار است. مکانیسم های **error back-propagation** که معمولاً در شبکه های عصبی معمولی استفاده می شود، به دلیل عدم تفاوت در زمان های اسپایک، نمی توانند مستقیماً به SNN منتقل شوند. در سطح تک سیناپس، آزمایشات نشان داده است که به نظر می رسد زمان دقیق اسپایک های قبل و بعد از سیناپسی نقش اساسی در تغییر کارایی سیناپسی دارد. با این قانون یادگیری - **Spike-Timing-Dependent-Plasticity (STDP)**، شبکه ها در کارهای مختلف آموزش داده شده اند.

اگرچه شبکه های مجهز به STDP روش قابل قبول بیولوژیکی تری برای استخراج ویژگی بصری ارائه می دهند، اما برای طبقه بندی محرک های ورودی به یک بازخوانی خارجی، به عنوان مثال، ماشین های برداری پشتیبانی (SVM) نیاز دارند. علاوه بر این، STDP تمایل به استخراج ویژگی های مکرر دارد که لزوماً برای کار مورد نظر مناسب نیستند.

چندین مطالعه نشان می دهد که سیستم پاداش مغز نقشی حیاتی در تصمیم گیری و شکل گیری رفتارها دارد. این امر به عنوان یادگیری تقویت (RL) نیز شناخته می شود، که به وسیله آن یادگیرنده ترغیب می شود که رفتارهای که موجب دریافت پاداش میشوند را تکرار کرده و از رفتارهایی که منجر به مجازات می شود پرهیز کند. دوپامین، به عنوان یک **neuromodulator**، یکی از مواد شیمیایی مهم در سیستم پاداشدهی مغز است. دوپامین و همچنین برخی دیگر از **neuromodulator** بر انعطاف پذیری سیناپسی تأثیر می گذارند، مانند تغییر در قطبیت یا تنظیم پنجره زمانی.

RSTDP یک قاعده یادگیری است که سیگنال پاداش **global** را با STDP ترکیب کرده است. این روش عملکرد **neuromodulator** را تقلید میکند. R-STDP ردیابی سیناپس های واجد شرایط STDP را ذخیره می کند و تغییرات وزن تعدیل شده را در زمان دریافت سیگنال تعدیل کننده اعمال می کند: پاداش یا مجازات. R-STDP شبکه را قادر می سازد ویژگیهای **task-specific** را پیدا کند، بنابراین هزینه محاسباتی سیستم تشخیص نهایی را کاهش می دهد.

از پیچیدگی های این روش میشود به دادن داده های حسگر به SNN، ساخت و اختصاص پاداش به نورنها و آموزش SNN اشاره کرد. سنسورهای داده معمولی معمولاً براساس زمان کار میکنند نه بر اساس اسپایک. برای اینکه دیتا را به SNN بدهیم باید آنرا به اسپایک تبدیل کنیم. وزن شبکه برای یادگیری نیز مهم است، در غیر این صورت فرآیند یادگیری زمان بیشتری را مصرف می کند یا حتی باعث شکست می شود.

قائده یادگیری R-STDP، با ترکیب مزایای یادگیری تقویت و سازوکار STDP، یک راه حل امیدوار کننده برای آموزش SNN ها ارائه می دهد. برا اساس یکی از مقالات¹ می توان گفت با این حال، از لحاظ پیچیدگی در ساخت و آموزش SNN، این قائده فاقد اجرای عملی رباتیک است. برای رفع این شکاف، در این تحقیق یک controller SNN را براساس R-STDP آموزش میدهند و آن را در کارهای حفظ مسیر برای یک ربات پایونیر پیاده سازی میکنند. اول، با استفاده از مزایای DVS برای دستیابی به داده ها، این الگوریتم در شرایط روشنائی سریع و قوی عمل میکند و قادر به یادگیری الگوهای مختلف جاده است. در مقایسه با static SNN controller، الگوریتم پیشنهادی عملکرد بهتری را از نظر انحراف ربات از خط مرکز نشان می دهد.

ساختار شبکه

در یک شبکه R-STDP از چهار لایه استفاده میشود. لایه اول شبکه (S1) بر اساس برجستگی لبه های جهت دار آن، تصویر ورودی را به تأخیر در اسپایک تبدیل می کند. این قطار اسپایک در لایه دوم (C1) تحت عملیات pooling محلی قرار می گیرد.

لایه سوم شبکه (S2) شامل چندین نورن Integrate-and-fire (IF) است که اطلاعات دریافتی لبه های oriented را ترکیب می کند و ویژگی های پیچیده را استخراج می کند. این لایه ورودی های خود را از سلول های عصبی C1 دریافت کرده و پس از رسیدن به پتانسیل آستانه، یک اسپایک ایجاد می کند. برای انعطاف پذیری سیناپسی، ما از یک قانون یادگیری استفاده می کنیم که بر اساس سه عامل تنظیم می شود: (1) زمان اسپایک پیش سیناپسی. (2) زمان اسپایک پس سیناپسی؛ و (3) سیگنال پاداش / مجازات. این نوع انعطاف پذیری سیناپسی توانایی کنترل رفتار نوروں ها را از نظر انتخاب آنها در الگوهای ورودی فراهم می کند. این تنها لایه قابل یادگیری در شبکه است که برای انعطاف پذیری سیناپسی از R-STDP استفاده می کند.

دومین لایه پیچیده (C2) شبکه، لایه تصمیم گیری است. سیگنال (پاداش / مجازات) برای modulate کردن انعطاف پذیری سیناپسی توسط لایه چهارم ارائه می شود که در آن تصمیم گیری شبکه اتفاق می افتاد. این شبکه فقط از اولین اسپایک منتشر شده توسط نوروںها در لایه سوم برای تصمیم گیری بدون استفاده از هیچگونه طبقه بندی کننده خارجی استفاده می کند. اگر تصمیم آن صحیح (نادرست) باشد، یک سیگنال پاداش (مجازات) global تولید می شود. علاوه بر این، به منظور افزایش راندمان محاسباتی، مانند آنچه در STDP داشتیم، به هر نورن در شبکه اجازه داده می شود که فقط یک بار در هر تصویر اسپایک بزند.

¹ End to End Learning of Spiking Neural Network based on R-STDP for a Lane Keeping Vehicle

motivation برای حداکثر یک اسپایک در هر نورون نه تنها از نظر محاسباتی بهینه است، بلکه مشابه حالت بیولوژیکی الهام گرفته هم هست. تصمیم گیری بدون هیچ طبقه بندی با حداکثر یک اسپایک در هر نورون، روش پیشنهادی را به یک روش مناسب برای پیاده سازی سخت افزار تبدیل می کند.

Overfitting

از مشکلات RL، میتوان به احتمال به دام افتادن در بهینه های محلی یا overfitting برای کسب حداکثر پاداش ممکن روی نمونه های آموزش وجود دارد. برای حل این مشکل در مرحله آموزش دو مکانیزم اضافی را اعمال می کنیم. این تکنیک ها فقط برای کارهای تشخیص شی استفاده می شود.

1. Adaptive Learning Rate
2. Dropout

Classification

همانطور که قبلا ذکر شد، فعالیت آخرین لایه، به ویژه اولین اسپایک در لایه C2، تنها اطلاعاتی است که شبکه ما برای تصمیم گیری نهایی در مورد محرک های ورودی استفاده می کند. به این ترتیب، به طبقه بندی کننده های خارجی نیازی نداریم.

برای راه اندازی شبکه برای یک تسک طبقه بندی با m دسته، $grid$ های نورونی به تعداد $n = k \times m$ را در لایه S2 قرار می دهیم (k تعداد ویژگی های مرتبط با هر دسته است). سپس، هر نورون C2 را توسط تابع ارتباط g به یک دسته اختصاص می دهیم $g : \{1, 2, \dots, n\} \rightarrow \{1, 2, \dots, m\}$ به شرح زیر تعریف شده است:

$$g(i) = \lfloor (i - 1) / k \rfloor + 1$$

سپس، شبکه محرک های ورودی را طبقه بندی می کند. در طول مرحله آموزش، تصمیم هر شبکه با برچسب محرک مقایسه می شود و در صورت تطبیق (عدم تطبیق) برچسب، سیگنال پاداش (مجازات) ایجاد می شود.

توضیحات کلی

اگرچه نتایج شبکه پیشنهادی به طور قابل توجهی بهتر از شبکه استفاده کننده از STDP با طبقه بندی کننده های خارجی است، اما هنوز با رویکردهای پیشرفته یادگیری عمیق قابل رقابت نیستند. یکی از محدودیت های

روش فعلی استفاده از تنها یک لایه قابل آموزش است. علاوه بر این، receptive field نورنها در لایه آخر به اندازه کافی بزرگ است که بتواند بخشی از تصویر که حاوی اطلاعات است را بپوشاند. در نتیجه، شبکه نمی تواند در برابر نرخ بالای تغییرات جسم مقاومت کند، مگر اینکه از تعداد بیشتری نورون استفاده کند. یکی از کارهایی که میتوان کرد افزایش تعداد لایه هاست. با این کار با یک استخراج تدریجی از ویژگی های ساده تا پیچیده، عملکرد را میتوان بهبود بخشید. با این حال، ساختار عمیق تر به تنظیم پارامتر بیشتری و یک قاعده انعطاف پذیری سیناپسی چند لایه مناسب نیاز دارد.

جمع بندی

یادگیری STDP پروسه‌ی یادگیری زیستی است که وزن سیناپس های بین نورون ها را وابسته به اختلاف زمانی نسبی نرون های pre و post تنظیم میکند. به این صورت که اگر نرون pre قبل از نرون post اسپایک زده باشد، آن اتصال بین دو نورون تقویت میشود و اگر ترتیب اسپایک ها برعکس باشد، آن اتصال تضعیف خواهد شد. (بازه ی زمانی بررسی معمولا 40 – 50 میلی ثانیه است)

در reward modulated STDP یا R-STDP بر اساس قواعدی که برای ایجنت تعریف شده است، بعد از تمام شدن تسک امکان دارد یک وزن موثر در نتیجه‌ی تسک، بر اساس اینکه خروجی تسک مطلوب باشد یا نه، reward یا punishment دریافت کند به این معنی که تقویت یا تضعیف شود. در این یادگیری، برخلاف STDP، از دوپامین به عنوان نروترنسمیتوری برای اعمال این پاداش یا مجازات استفاده می شود. به این صورت که با ltp یا ltd متغیری را مانند برچسب، جفت می کنیم تا نشان دهنده ی نوع ltp یا ltd باشد و در آخر هر مرحله ی یادگیری، اگر دوپامین ترشح شد، با توجه به برچسب گفته شده، وزن آن اتصال را تغییر خواهیم داد. R-STDP در مسائلی کاربردی است که بتوان آن ها را در فضای یادگیری تقویتی تعریف کرد.